

Pytania Data Science — podstawy / Data Science fundamentals questions

Zestaw pomocniczy do przygotowania z zakresu Data Science / ML Supplementary set for Data Science / ML preparation

UWAGA / NOTICE: To są przykładowe pytania, które mogą pojawić się na obronie — nie oficjalna lista PJATK. / These are example questions that may appear at a defense — not an official PJATK list. See DISCLAIMER.md.

Każde pytanie podano po polsku i po angielsku. Powtarzające się zagadnienia z różnych list źródłowych umieszczono tylko raz. / Each question is given in Polish and English. Overlapping topics from source lists appear only once.

Metryki, ewaluacja i walidacja / Metrics, evaluation and validation

1.

PL: Czym są metryki w uczeniu maszynowym? Podaj przykłady metryk dla klasyfikacji i regresji oraz krótko wyjaśnij, kiedy której użyć.

EN: What are metrics in machine learning? Give examples of metrics for classification and regression and briefly explain when to use which.

2.

PL: Co to jest macierz pomyłek (confusion matrix)? Jakie wartości się w niej znajdują i jak na jej podstawie policzyć accuracy, precision i recall?

EN: What is a confusion matrix? What values does it contain, and how can accuracy, precision and recall be computed from it?

3.

PL: Czym różni się precision, recall i F1-score? Kiedy F1 jest lepszym wyborem niż samo accuracy?

EN: How do precision, recall and F1-score differ? When is F1 a better choice than accuracy alone?

4.

PL: Co to jest krzywa ROC i AUC? Jak interpretować AUC w zadaniu klasyfikacji binarnej?

EN: What are the ROC curve and AUC? How do you interpret AUC in a binary classification task?

5.

PL: Co to jest walidacja krzyżowa (cross-validation)? Omów ideę k-fold CV oraz po co się jej używa.

EN: What is cross-validation? Discuss the idea of k-fold CV and why it is used.

6.

PL: Czym różni się stratified k-fold od zwykłego k-fold? Kiedy warto stosować walidację leave-one-out?

EN: How does stratified k-fold differ from plain k-fold? When is leave-one-out validation useful?

7.

PL: Po co dzieli się dane na zbiór treningowy, walidacyjny i testowy? Co grozi, jeśli test używa się wielokrotnie do doboru modelu?

EN: Why split data into train, validation and test sets? What goes wrong if the test set is reused repeatedly for model selection?

Modele i trenowanie / Models and training

8.

PL: Wymień i krótko scharakteryzuj podstawowe typy modeli uczenia maszynowego (nadzorowane, nienadzorowane, uczenie przez wzmocnienie) oraz podaj przykłady zadań dla każdego typu.

EN: List and briefly characterise the basic types of machine learning models (supervised, unsupervised, reinforcement learning) and give example tasks for each type.

9.

PL: Omów podstawowe sposoby trenowania modeli ML: podział train/validation/test, uczenie wsadowe vs przyrostowe, transfer learning oraz dostrajanie hiperparametrów.

EN: Discuss basic ways of training ML models: train/validation/test split, batch vs incremental learning, transfer learning and hyperparameter tuning.

10.

PL: Czym różni się regresja liniowa od regresji logistycznej? Do jakich typów zadań się je stosuje?

EN: How does linear regression differ from logistic regression? Which task types is each used for?

11.

PL: Omów ideę drzew decyzyjnych oraz zespołów (np. Random Forest, gradient boosting). Jakie są zalety podejść ensemble?

EN: Discuss decision trees and ensembles (e.g. Random Forest, gradient boosting). What are the advantages of ensemble methods?

12.

PL: Co to jest funkcja straty (loss function)? Podaj przykłady dla klasyfikacji i regresji.

EN: What is a loss function? Give examples for classification and regression.

13.

PL: Co to jest gradient descent? Krótko wyjaśnij rolę learning rate.

EN: What is gradient descent? Briefly explain the role of the learning rate.

14.

PL: Czym są hiperparametry modelu i czym różnią się od parametrów uczonych podczas treningu? Podaj przykłady.

EN: What are model hyperparameters and how do they differ from parameters learned during training? Give examples.

Dane, cechy i jakość modelu / Data, features and model quality

15.

PL: Co to jest przeuczenie (overfitting) i niedouczenie (underfitting)? Jak je rozpoznać i jak im przeciwdziałać?

EN: What are overfitting and underfitting? How can they be recognised and mitigated?

16.

PL: Czym różni się bias od variance w kontekście błędu modelu? Jak ten kompromis wpływa na wybór złożoności modelu?

EN: How do bias and variance differ in the context of model error? How does this trade-off affect the choice of model complexity?

17.

PL: Co to jest regularizacja (np. L1/L2)? Po co się ją stosuje?

EN: What is regularisation (e.g. L1/L2)? Why is it used?

18.

PL: Omów typowe problemy jakości danych: braki, duplikaty, outliery, nieszczelność danych (data leakage). Jak im zapobiegać?

EN: Discuss typical data-quality issues: missing values, duplicates, outliers, data leakage. How can they be prevented?

19.

PL: Co to jest feature engineering? Podaj przykłady transformacji cech dla danych tabelarycznych.

EN: What is feature engineering? Give examples of feature transforms for tabular data.

20.

PL: Czym jest normalizacja i standaryzacja cech? Kiedy warto je stosować?

EN: What are feature normalisation and standardisation? When are they useful?

21.

PL: Co to jest niezbalansowany zbiór klas? Jakie strategie pomagają (ważenie klas, resampling, inne metryki)?

EN: What is class imbalance? Which strategies help (class weighting, resampling, alternative metrics)?

Proces DS, MLOps i etyka / DS process, MLOps and ethics

22.

PL: Co to jest potok (pipeline) przetwarzania danych w projekcie Data Science? Wymień typowe etapy od surowych danych do wdrożenia modelu.

EN: What is a data-processing pipeline in a Data Science project? List typical stages from raw data to model deployment.

23.

PL: Co to jest reprodukowalność eksperymentu ML? Jakie elementy trzeba wersjonować (kod, dane, seed, środowisko)?

EN: What is reproducibility of an ML experiment? Which elements should be versioned (code, data, seed, environment)?

24.

PL: Czym różni się monitoring modelu w produkcji od ewaluacji offline? Co to jest drift danych / koncepcji?

EN: How does production model monitoring differ from offline evaluation? What is data / concept drift?

25.

PL: Omów krótko ryzyko biasu i fairness w modelach ML. Podaj przykład, kiedy model może być niesprawiedliwy.

EN: Briefly discuss bias and fairness risks in ML models. Give an example where a model may be unfair.

26.

PL: Co to jest baseline w projekcie ML i dlaczego warto go mieć przed budową złożonego modelu?

EN: What is a baseline in an ML project and why is it useful before building a complex model?

27.

PL: Czym różni się uczenie wsadowe (batch) od uczenia online / strumieniowego? Podaj przykładowe zastosowania.

EN: How does batch learning differ from online / streaming learning? Give example use cases.

Łączna liczba pytań / Total number of questions: 27